## **DSA HW2 hints**

陳步青、周紀寧、劉承昌

## 一、參考資料結構

### (0) 資料介紹:

In this homework, we are required to process a 5-dimension sparse array. Since it is sparse, we should not use a real 5-D array to save these data, because the empty entries alone would take more memory than we have. So here we give two example data structures for handling the data.

### (1) Sparse array:

Given a sparse array, how do we save all its entries? Take the following matrix for example:

row/col	0	1	2	3	4	5	6	7	8
0									
1		9						8	
2					10				
3									
4			3						
5						2			
6									
7				1					
8									

This is a 9x9 array, but only 6 'real' entries exist. Can we do better than using 81 \* sizeof(entry) memory for this array?

One idea is to compress it into a 1-D array. Each entry is (row,column,value). The array becomes the following:

(1,1,9) (2,4,10)	(4,2,3)	(5,5,2)	(1,7,8)	(7,3,1)	
------------------	---------	---------	---------	---------	--

You can see that we used almost optimal space to save the entries. But the search speed is O(number of entries), which is very slow.

Another idea is to compress it into a 1-D array of shorter arrays

row		
0	NULL	
1	(1,9)	(7,8)
2	(4,10)	
3	NULL	
4	(2,3)	
5	(5,2)	
6	NULL	
7	(3,1)	
8	NULL	

Now we take some more space, but searching via the row index is O(1), and the remaining search can speed up via binary search.

1-D壓縮的資料結構,就是文字檔的儲存方式。它將 5欄的資料變成entry的一部分,總共 1.4億筆資料存起來。

### Data Structure 1:

Load all the data into a 1-d array, then sort all the data by user -> adid -> advertiser ... If you do this with proper optimization, you can finish all the test data in 40 mins.

The query time for DS1 can be done as follows:

get(u,a,q,p,d): O(log n)

clicked(u): O(logn) + O(# of impressed ads of u)

impressed(u1,u2): O(logn) + O(# of impressed ads of u1 & u2)

profit(a,theta): O(n), or O(log n)

Implementation: Hidden, please ask TA.

如果覺得1-D不夠快的話可以做2-D壓縮。這邊**不負責任**提供資料資訊:

user id總共有22023547筆,但是最大的user id是23907634。因此可以直接開一個23907634大小的陣列,直接存每個user的資料。雖然有~200萬筆空的user,但是相當的省時間,查user只需要O(1),剩下的資料量也從1.4億降到最大90萬。

user	vector <data></data>
0	data with u = 0
1	data with u = 1
2	data with u = 2
	.   .
23907634	data with u = 23907634

#### Data Structure 2:

Load all the data into a 2-d array, use user\_id as first array index, then sort all the data by adid -> advertiser ...

If you do this with proper optimization, you can finish all the test data in 30 mins.

The query time for DS1 can be done as follows:

```
get(u,a,q,p,d): O(log (entries of u))
clicked(u): O(log (entries of u)) + O(# of clicked ads of u)
impressed(u1,u2): O(# of impressed ads of u1 & u2)
profit(a,theta): O(#users the impressed on a)
```

Implementation: Hidden, please ask TA.

```
(*) O(n) comparison algorithm:
有兩串資料,要怎麼找出共同的資料呢?
方法一:
for entry1 in array1:
    for entry2 in array2:
        if(entry1 == entry2):
            output entry1
這個方法要O(n^2)時間,但是排序過,可以更快!!
方法二:
    sort(array1)
    sort(array2) // O(nlogn) time
i = 0; j = 0;
```

```
while (i < array1.size && j< array2.size){
    if(array1[i] < array2[j])
        i++;
    else if(array1[i] > array2[j])
        j++;
    else if(array1[i] == array2[j])
        output array1[i]
        i++;j++;
}
```

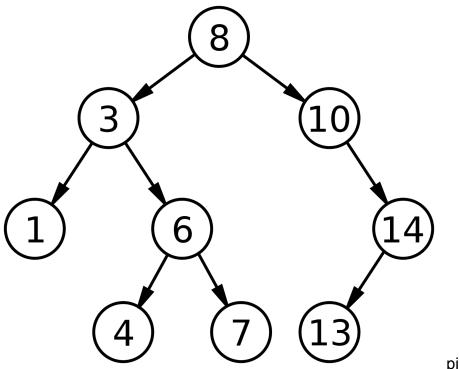
因為排序過,保證輸出不重複,比對次數也變少。不算排序只要O(n)時間。 在impressed中,可以先用這個演算法找出共同的adid,再用相同的演算法,輸出兩者出 現的properties.

# (2) std::Map

在C++ stl裡面,有一個神奇的東西叫做map. 老師到很晚才說可以用,不然我們不會在這裡寫。



老師說:可以跟同學說用法跟array一樣。 但我覺得還是要說一下,map其實是一個binary search tree.



picture from wiki

所以能夠支援跳來跳去的index.

用這個的人,希望你們自己去查他的效能,寫在report裡面。 大O分析,會跟array差不多。但因為是stl,所以比較肥、慢。不建議用五層。 可以

user 用array, adid當map ...

map <int,ad></int,ad>	map <int,other_data></int,other_data>
0	
1	
2	
23907634	

Data Structure3,4,5...:
vector<map<vector<data>>>
map<<map<data>>> ...

### 二、報告撰寫

### 跟手寫一起繳交, **兩頁以內, 清楚即可**, 建議包含以下內容:

Emphasize on why you think the data structure would be (time-wise) efficient for the four desired actions

- 1. 分步驟解釋實作的過程 (一定要寫)
  - a. 如何處理讀檔?用什麼資料結構存?為什麼?
  - b. 四個函式怎麼實作的,各用什麼演算法在你的資料結構中做搜尋?有先Sort過嗎?為什麼這樣做?這些做法的時間複雜度各是?
    - i. Get
    - ii. Clicked
    - iii. Impressed
    - iv. Profit
- 2. 時間 (optional)
  - a. 讀檔案時間
  - b. 四個指令分別花的平均時間
- 3. 你是如何有效率的寫完這次作業?跟同學討論還是找TA協助還是自幹?有沒有團隊合作或是組讀書會?希望TA提供哪些東西,對你們完成作業會更有幫助?(optional)

# 三、優化 (痛苦指數: 1~5)

可以少一層,省很多記憶體。 \*\*map很肥

Compiler Optimization: (痛苦指數: 0, 加速: 大大大)

• Try the -O2 or -O3 option, either on g++ or gcc.

### Misc:

● 用C寫, 速度會比C++快一點點 (痛苦指數: 3, 加速: 少少) Use C to implement, it is a little bit faster than C++

下面很多優化都是假設你用C寫,因為C比較接近系統

● 狀態壓縮 (痛苦指數: 0, 加速: 少) depth, position <=3, 多用一個index很浪費,不如用3\*depth+position。 5層map就

## **Algorithms:**

online sorting

用前面DS2的寫法時,每個user所存的資料不用先排好,因為排好也不一定會查到。所以可以等備查到的時候再排序。

no sorting

如果為四個函數分別寫四個資料庫,那get、clicked這兩個函數可以不用做排序。因為分析助教只有1200筆測資,重複出現的應該不多。兩個函數如果做排序,第一次要O(nlogn)時間,之後都是O(log n),不排序的話只要一次O(n)時間,會比較快。

pointer sorting

為四個函數分別寫四個資料庫,可以都用指標陣列,排序快速,也不會多用太多記憶體。

### **Light weight STL:**

• vector (痛苦指數: 2, 加速: ?)

vector實際上是一個growing array, 支援均攤O(1)寫入,在ADA會介紹。實作概念是**滿了** 就長兩倍。以下psudocode

//這邊省略掉初始化malloc. 以及realloc的時候要先檢查有沒有realloc成功等步驟。

• map (痛苦指數: 2, 加速:?)

map 相當肥,也不好寫。好在**linux/rb\_tree.h**有一個**效能非常好**的紅黑樹。他是kernel在系統排成的時候用的資料結構,所以寫得很有效率。可以直接用。

另外、MIT也有實作紅黑樹:

http://web.mit.edu/~emin/www.old/source\_code/red\_black\_tree/index.html都可以研究一下拿來用。

# Loading data:

Here we list functions faster than fstream. fstream

- scanf(): 3分30秒 (痛苦指數: 1, 加速: 多)
- fgets(): 未測試 (痛苦指數: 2, 加速: 多)
- fread(): 未測試
- open()、read():未測試
- mmap (痛苦指數: 5, 加速: 快1.7倍)

mmap是一個把檔案整個讀進記憶體的函式,相當快速。整的load完+parse完只要1分59秒。以下為林祥瑞的範例code。

```
173
174
175
176
177
178
179
180
182
183
184
185
186
187
198
199
191
192
193
194
195
196
          int fd_data = open(argv[1], O_RDONLY);
if (fd_data < 0)</pre>
               fprintf(s
                                                   pen file\n");
               return errno;
          struct stat stat_buf;
          if (fstat(fd_data, &stat_buf))
               fprintf(stderr, "cannot stat file\n");
return errno;
          void *data_begin = mmap (NULL, stat_buf.st_size, PROT_READ | MAP_POPULATE | MAP_HUGETLB, MAP_SHARED, fd_data, 0);
if (data_begin == MAP_FAILED)
                               err, "cannot mmap file\n");
               fprintf(sto
               return errno;
          void *data_end = data_begin + stat_buf.st_size;
          if (close(fd_data))
                fprintf(s
                return errno
```

### **Avoiding System Call Malloc:**

獨立出來寫是因為加速超多。已以往經驗,DSA的final project都可以<mark>節省一半以上的時間。但寫起來也相當痛苦。</mark>

解釋一下,要求動態配置的記憶體時,會經過很多層的system call,等作業系統處理你的要求。相當花時間。

替代的方法是用國際空間,也就是 data\_segment的記憶體。

(系統程式設計會講, function call在stack 上面, malloc在heap上面)

```
1 #include
 2 #include
3 #include
 4 #include
 5 #include
 6 #include
8 #include
10 char memory pool[200000000];
11 char *cur pos;
13 int main(int args, char *argv[]){
14
       //初始化沒用到的位置
15
       cur pos = memory pool;
16
17
18
       struct raw data db raw data;
19
       if(args<2){
20
           printf("
                    r fail<mark>u</mark>re);
21
           exit(EX
```

## **Parallel Programming:**

openmp

```
5 #include<omp.h>
6
7 #pragma parallel for
8 for (int i = 0;i<10;i++){
9    printf("%d\n",i);
10 }</pre>
```

openmp是很容易上手的平行畫,可以直接平行單一迴圈。 好人教學:

https://kheresy.wordpress.com/2006/06/09/%E7%B0%A1%E6%98%93%E7%9A%84%E7%A8%8B%E5%BC%8F%E5%B9%B3%E8%A1%8C%E5%8C%96%E6%96%B9%E6%B3%95%EF%BC%8Dopenmp%EF%BC%88%E4%B8%80%EF%BC%89%E7%B0%A1%E4%BB%8B/

### pthread

pthread稍微難寫一點。助教一開始就想要用平行寫,所以四個函式就直接用三個資料結構存,可以平行建造,所以不多花時間。有興趣的人自己研究。

```
struct get clicked ds gc db;
19
          struct impressed db impressed ds;
20
          struct profit ds profit db;
21
          pthread t t[3];
22
          //make threads
         pthread_create(t, NULL, make_get_clicked, (void*) raw_data);
pthread_create(t+1, NULL, make_impressed_db, (void*) raw_data);
pthread_create(t+2, NULL, make_profit_db, (void*) raw_data);
// wait for threads to finish and catch return value
23
24
25
26
27
          void *rt val;
28
          pthread join(t[0],&rt val);
          gc db = *(struct get clicked ds*) rt val;
29
30
          pthread join(t[1],&rt val);
31
          gc db = *(struct impressed ds*) rt val;
32
          pthread join(t[0],&rt val);
33
          gc db = *(struct profit ds*) rt val;
```